

Raport Końcowy z Projektu Autonomiczne Systemy Ekspertyzy i Eksploracji danych

System Detekcji Anomalii Temperatury

Tomasz Nazar 197613

Filip Pietrzak 198275

Czerwiec 2026

Streszczenie

Niniejszy raport dokumentuje architekturę, metodykę statystyczną oraz wyniki działania zautomatyzowanego systemu do detekcji anomalii temperatury. System został zaprojektowany do monitorowania stacji meteorologicznej GDN_01 poprzez pobieranie danych API, normalizację za pomocą wskaźnika Z-Score w oknie kroczącym (rozmiar 24) i wyciąganie wniosków w postaci wyselekcjonowanych tabelarycznie anomalii lub najlepszych kandydatów wraz z wizualizacjami analitycznymi.

1 Wprowadzenie i Cel Projektu

Zasadniczym celem projektu była automatyzacja analizy danych i budowa data pipeline, który potrafi odróżnić dobowe, naturalne fluktuacje temperatur od błędów technicznych stacji pomiarowych.

2 Architektura Systemu (Data Pipeline)

Zaproponowane rozwiązanie wdraża trójwarstwową architekturę zarządzania danymi, minimalizując błędy zapisu i utratę danych historycznych.

- **Dane Surowe (Raw Data Ingestion):** Pobieranie paczek z danymi (200 rekordów) z punktu końcowego AWS API przy użyciu protokołu REST. Otrzymana odpowiedź zachowywana jest bezpośrednio w formacie JSON (np. `raw_weather_YYYYMMDD_HHMMSS.json`), co gwarantuje archiwizację oryginalnych danych i umożliwia powtórne przeliczenie w przypadku zmiany programu.
- **Dane Przetworzone (Processed Layer):** Płaska warstwa przygotowana do analizy statystycznej. Obejmuje normalizację znaczników czasowych oraz wektoryzowane przeliczanie parametrów matematycznych (μ oraz σ) korzystając z biblioteki `pandas`. Wynik to tabela z wyliczonym polem `z_score`.
- **Dane Kurowane (Curated Outputs):** Zapis wyników obejmuje warstwę kurowaną oraz wykres `anomaly_chart.png`. Raportowana jest wyłącznie tabela z wyizolowanymi błędami.

3 Metodyka Statystyczna - Algorytm Z-Score

Detekcja odstępstw od normy opiera się na analizie odchylenia standardowego i wskaźniku Z-Score w ruchomym oknie czasowym (rolling window).

3.1 Określenie okna analizy lokalnej

Szerokość okna ustalono na parametr `window_size = 24`. Tak przyjęta wielkość odpowiada cyklowi dobowemu temperatury. Usuwa to ryzyko błędnego identyfikowania ochłodzenia porannego jako błędu.

3.2 Baza obliczeniowa

Dla każdego punktu danych x_i wskaźnik Z-Score liczony jest według poniższego wzoru, wykorzystując średnią (μ) oraz odchylenie standardowe (σ) z historii pomiarów:

$$Z_i = \frac{x_i - \mu_{window}}{\sigma_{window}} \quad (1)$$

Aby anomalia sama w sobie nie zawyżyła sztucznie odchylenia standardowego i średniej (co spowodowałoby *wyciszenie* detekcji), kod precyzyjnie wdraża komendę przesunięcia serii (`shift(1)`). Bieżący punkt mierzony nie należy więc do własnego okna ewaluacyjnego.

3.3 Bezpieczeństwo obliczeniowe (Edge Cases)


Błąd dzielenia przez zero mógłby wystąpić, gdyby temperatura przez dłuższy czas utrzymywała się na tym samym poziomie (odchylenie równe zero). Aby temu zapobiec, zastosowano proste zabezpieczenie kodu:

```
1 df['rolling_std'].bfill().fillna(0.1).replace(0, 0.1)
```

Powyższa instrukcja podmienia zerowe oraz nieliczbowe (NaN) wartości wariancji na bezpieczne matematycznie 0.1, eliminując błąd dzielenia przez zero.

4 Wyniki i Metryki

Domyślna czułość (`z_score_threshold`) została ustanowiona na poziomie **2.0**. Taki próg gwarantuje optymalny kompromis pomiędzy nadwrażliwością algorytmu (false positives) a przeoczeniami (false negatives).



Rysunek 1: Wizualizacja detekcji anomalii temperatury dla stacji GDN_01

Wariant wizualizacji	Warunek aktywacji	Kolor wyróżnienia	Etykiety
Wykryta anomalia	$ Z > 2.0$ (co najmniej 1 rekord)	Czerwony	Pełny Z-score
Tryb aapasowy (Fallback)	Brak twardych anomalii ($ Z < 2.0$)	Pomarańczowy	Top 5 Z-score
Pomiary standardowe	Norma / Cała reszta w oknie	Niebieski	Brak

Tabela 1: Macierz decyzyjna warstwy `Output Generation` dla stacji GDN_01

Dzięki trybowi *Fallback* wykresy są przydatne nawet wtedy, gdy pogoda jest stabilna i nie ma żadnych awarii. W takie spokojne dni system na wszelki wypadek zaznacza 5 punktów, które najbardziej różniły się od normy.

5 Wnioski

- Czas wykonania:** Biblioteka `pandas` obrabia pełną serię 200 rekordów (sortowanie, shift, rolling, przeliczanie indeksu) poniżej kilkuset milisekund dzięki wektoryzacji operacji.
- Modułowość:** Kod przygotowano bez stanu globalnego. Każda warstwa potoku ma oddzielną logikę w procedurach: `fetch_and_store...`(), `process_data()` oraz `generate_outputs()`.
- Czytelność wykresów:** Nad najważniejszymi punktami na wykresie automatycznie pojawiają się konkretne liczby (np. $Z=2.84$). Dzięki temu nie trzeba ręcznie przeglądać setek liniiek w plikach tekstowych.